

75.06 Organización de Datos

Trabajo Práctico N°2 **Machine Learning**

Grupo 7

Nombre del grupo: Cobra Kai

Integrantes del grupo:

Nombre	Padrón
Eleonora Luna	96444
Germán Bobadilla	90123
Antonella Briglia	90903
Santiago Schuchinsky	96400

1er Cuatrimestre 2018

Pre-procesamiento de datos

Duplicados en csv

Para lidiar con este problema, se comenzó por eliminar los duplicados en cada csv. Es decir, si alguna fila era idéntica a otra esa fila fue eliminada. También podía pasar, como en el caso del csv con la información sobre el género y la edad de los postulantes, que un id de postulante estuviese repetido con distinta información. En ese caso, se preservó la última entrada, ya que se supone que esa fue la última actualización de la información realizada por el postulante.

Valores NaN

Algunos csv contenían valores NaN. Por ejemplo, en el csv que contiene la información sobre el género y edad de los postulantes, la columna de 'fechanacimiento' contenía varios valores Nan. Por lo tanto, a la hora de crear una columna 'Edad', a esos valores se los rellenaron con la media de la edad de esos postulantes. En el csv de detalles de avisos, en la columna de 'nivel laboral', también habían varios valores Nan, por lo tanto se rellenaron con el label 'Otro'.

En aquellos casos en los cuales la mayoría de los valores de las columnas eran Nan, decidimos descartarlas por completo ya que se consideró que no aportan suficiente información para lograr el trabajo. Unos ejemplos de este caso fueron la columna 'mapacalle' y la columna 'ciudad' del csv de los detalles de los avisos.

Valores Inválidos

En otros casos, los csv contenían valores inválidos. Por ejemplo, en el csv que contiene la información sobre el género y edad de los postulantes, en la columna 'género' habían un par de valores que eran '0.0'. Por supuesto que no es un valor representativo para dicha columna, por lo tanto, se reemplazaron estos valores por 'NO_DECLARA'.

Datos faltantes de idavisos

Analizando el csv de postulaciones se encontraron varios id de avisos que no aparecían en el csv de detalles de los avisos. Por lo tanto, no se contaba con información alguna de estos y al hacer un merge con el dataframe de postulaciones muchos valores quedaban en NaN. Como ninguno de estos avisos formaba parte del set que se quería predecir, se decidió descartar estos avisos ya que no aportaban información suficiente.

Datos a predecir en set de entrenamiento

Se pudo observar que en el csv de postulaciones “hasta el 15 de abril” aparecían postulaciones hasta el 17 de abril inclusive, con lo cual varios de los datos que se querían predecir formaban parte del set de entrenamiento. Para evitar la mala predicción se decidió crear una función que elimina las tuplas que forman parte del set de datos a predecir.

Outliers

Al calcular las edades de los postulantes mediante la fecha de nacimiento que fue provista, se pudo observar que habían postulantes con edades de 7 a 245 años. Algunas de ellas claramente imposibles de ser reales y otras que entran en un rango menor a los 18 años. Antes de eliminarlos, se chequeó si la edad de alguno de los postulantes que se encontraban entre los datos a predecir entraba en estos rangos. Como se encontraron varias edades por debajo de los 18 años y un par arriba de los 100 años, se decidió eliminar solo aquellas que se encontraban fuera del rango de los datos que se querían predecir.

Tuplas de gente postulada y no postulada

Para poder entrenar se necesitaban tanto las tuplas de gente que se postuló a algún aviso y las tuplas de gente que no se postuló a algún aviso.

Para eso se utilizaron las tuplas (idpostulante,idaviso) del csv de postulaciones como las tuplas para la gente postulada.

Para la gente no postulada, se utilizaron los 'idpostulante' del csv de postulaciones y se samplearon junto con todos los 'idaviso' posibles. Al hacer esta intersección podía pasar que algunas tuplas formarían parte del csv de postulaciones, por lo tanto, esas tuplas se descartaron y de esta manera se logró obtener samples de la gente no postulada.

Feature Engineering

Feature Género

Al ser pocos los valores que podía abarcar la columna 'Género', se decidió aplicar un One Hot Encoding para cada uno de esos valores. En este caso: FEM, MASC, o, NO_DECLARA.

Feature Edad

Para este feature se probaron varias opciones. Primero dejamos la edad calculada según la fecha de nacimiento sin alterar.

Luego, se probó dividiendo las edades en distintos grupos por rango. Se probaron varias combinaciones de rangos y luego, a cada rango se le aplicó un one hot encoding.

Se pudo observar, luego de varios intentos, que la opción que dio mejores resultados fue la primera.

Feature Educación

En este caso se decidió asignarle un peso a cada estado del nivel de estudio. Los estados que existen son : Graduado, En Curso o Abandonado. Como se considera más relevante que alguien se haya graduado de algún nivel educativo le asignamos un peso mayor a este estado, el segundo peso a 'En Curso' y por último al estado 'Abandonado'. Se generó una columna por cada nivel educativo y luego, para cada fila se preservó el valor más alto obtenido en ese nivel educativo.

Por ejemplo, si un postulante aparece dos veces con nivel Universitario y una vez con estado 'Graduado' y otra vez con estado 'En Curso', se preserva el mayor, es decir, el estado Graduado. El otro, se descarta. Si no existe información para algún postulante para un cierto nivel, se rellena con ceros.

Feature Nombre Área de Trabajo (Ventas, Adm,etc)

En este caso, las áreas de trabajo eran bastantes y muchas de ellas eran áreas más específicas de un área más general. Por lo tanto, se decidió

reducir las áreas e incluir esas áreas más específicas en las áreas más generales.

Por ejemplo, todas las ingenierías fueron incluidas en una sola área llamada 'Ingeniería'. De esta manera, logramos reducir considerablemente la cantidad de áreas y una vez hecho esto aplicamos un One Hot Encoding para cada una de ellas. Comparamos el resultado con el resultado obtenido aplicando un One Hot Encoding sin reducir las áreas y el resultado fue considerablemente mayor.

Feature Tipo de Trabajo,Nivel Laboral,Nombre Zona

Estas tres características formaban parte del csv de los detalles de los avisos. Las tres contaban con una cantidad de valores menor, por lo tanto se decidió probar con dos opciones. Una fue aplicar un One Hot Encoder y la otra aplicar un label encoder sobre los valores existentes. Se pudo observar, que la primera opción logró mejores resultados para cada característica.

Feature vistas

En este caso se decidió crear una columna llamada 'Visto' la cual indica si cierta tupla (idaviso, idpostulante) está incluida o no en el csv de vistas. Es decir si ese postulante visitó alguna vez ese aviso. La columna se rellena con un 1 si está incluida y con un 0 si no lo está. El 1 representa que el postulante visitó el aviso y el 0 que no lo hizo.

Feature tasa de postulación de aviso y postulante

Para este feature, primero se obtuvo la cantidad de vistas y postulaciones para cada aviso. Luego se realizó la división de la cantidad de postulaciones sobre la cantidad de visitas, obteniendo así un valor entre 0 y 1 que representa la tasa de postulación de cada aviso. Se realiza la misma operatoria para los postulantes obteniendo la tasa de postulación de cada uno.

Algoritmos probados

Random Forest Classifier

Este algoritmo fue uno de los cuales obtuvo mejores resultados. La desventaja que presentó es que tardaba un tiempo considerable para llegar al resultado.

Gradient Boosting Classifier

Este algoritmo variaba bastante. A veces daba peores resultados que el Random Forest y a veces apenas mejor. También, tardaba bastante tiempo en calcular el resultado

Decision Tree Classifier

Este algoritmo logró casi siempre un resultado muy parecido al Random Forests. Pero, la gran ventaja fue que el tiempo que tardaba en calcular el resultado era considerablemente menor.

Perceptron

Este algoritmo es el que menor tiempo tardaba en correr, pero los resultados obtenidos eran un poco más bajos que los demás.

Naive Bayes

Algoritmo con mejor resultado:

Score obtenido:

Performance:

Parámetros usados:

Conclusiones

Se pudo observar que los features que más relevancia y mas información aportaron fueron aquellos que estaban relacionados con las vistas de los avisos. Lo cual tiene sentido ya que es mucho más probable que una persona se postule a un aviso si lo vio previamente o si vio algún aviso con características similares.

También, el nombre del área de los avisos complementada con el género de los postulantes logró incrementar el score de las predicciones. En el Trabajo Práctico anterior se había podido notar que si bien habían areas comunes en las preferencias de hombres y mujeres, habían muchas otras que no aparecían en el ranking de uno o de otro, o incluso otras que si aparecian pero variaban las preferencias.

Por otra parte, en cuanto a la educación se había podido observar que la mayoría de los postulantes que tenían como estado de sus estudios 'abandonado' no eran muy propensos a postularse a algún trabajo. Al ponderar estos estados, teniendo en cuenta los resultados obtenidos anteriormente, se vio reflejada la suba en la precisión de las predicciones.

Además, como se había podido observar en el Trabajo Práctico anterior, las edades de los postulantes tienen un rango muy amplio. Pero la mayoría de los postulantes tienen una edad que está en el rango de los 20 a 30 años y dentro de ese mismo rango las postulaciones eran muy diversas. Con lo cual se puede deducir que por ese motivo resultó en un mejor resultado dejar las edades como estaban y no diferenciarlas por rango ya que no aportaban más información.

Por último, ciertos features consiguieron una suba de la precisión pero en cantidades mínimas. Como por ejemplo, el nombre de la zona del aviso, el tipo de trabajo y el nivel laboral.

Otras características que no aportaron información fueron aquellas en las cuales los datos eran pocos o los valores eran los mismos para todos los casos. Por ejemplo, el id del país era el mismo para todos los avisos y en el caso de la característica 'mapacalle' la mayoría de los datos eran NaN, con lo

cual se cree que es un campo que muchas personas deciden no completar y no aporta información para este trabajo.

Link al repositorio de Github

<https://github.com/czuczinsky/TP2-Machine-Learning>